

1. НАИВНЫЙ БАЙЕС И ЦЕНТРОИДНЫЙ КЛАССИФИКАТОР

Вероятность того, что элемент $x = (x_1, \dots, x_n)$ принадлежит классу y :

$$P(y|x_1, \dots, x_n) = \frac{P(y)P(x_1, \dots, x_n)}{P(x_1, \dots, x_n)} \stackrel{\text{предп. незав.}}{=} \frac{P(y) \prod_{k=1}^{k=n} P(x_k|y)}{\prod_{k=1}^{k=n} P(x_k)}$$

Найдем наиболее вероятный класс для данного x :

$$\begin{aligned} \hat{y} &= \arg \max_y \frac{P(y) \prod_{k=1}^{k=n} P(x_k|y)}{\prod_{k=1}^{k=n} P(x_k)} \stackrel{\text{без констант}}{=} \arg \max_y P(y) \prod_{k=1}^{k=n} P(x_k|y) \stackrel{P(y) - \text{константа}}{=} \arg \max_y \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{\sum_{k=1}^{k=n} (x_k - \mu_{yk})^2}{2\sigma^2}} = \\ &= \arg \max_y e^{-\frac{\sum_{k=1}^{k=n} (x_k - \mu_{yk})^2}{2\sigma^2}} = \arg \min_y \sum_{k=1}^{k=n} (x_k - \mu_{yk})^2 \end{aligned}$$

Легко заметить, что это то же самое, что евклидовое расстояние в квадрате между x и μ_y . Таким образом, классификация сводится к отнесению объекта x к классу y , центр которого μ_y ближе всего к x , что и требовалось доказать.

2. ROC-AUC СЛУЧАЙНЫХ ОТВЕТОВ

Пусть n – число объектов в выборке, k – число объектов первого класса. Тогда:

$$\begin{aligned} \frac{TP}{n} &= P(x \in \mathbf{1}) \cdot P(a(x) = 1) = \frac{k}{n}p \\ \frac{FP}{n} &= P(x \notin \mathbf{1}) \cdot P(a(x) = 1) = \frac{n-k}{n}p \\ \frac{TN}{n} &= P(x \notin \mathbf{1}) \cdot P(a(x) = 0) = \frac{n-k}{n}(1-p) \\ \frac{FN}{n} &= P(x \in \mathbf{1}) \cdot P(a(x) = 0) = \frac{k}{n}(1-p) \\ TPR &= \frac{\frac{k}{n}p}{(\frac{k}{n}p + \frac{k}{n}(1-p))} = p \\ FPR &= \frac{\frac{n-k}{n}p}{(\frac{n-k}{n}p + \frac{n-k}{n}(1-p))} = p \end{aligned}$$

Таким образом, $TPR = FPR$ не зависимо от p и k .

3. ОШИБКА 1NN И ОПТИМАЛЬНОГО БАЙЕСОВСКОГО КЛАССИФИКАТОРА

$$\begin{aligned} E_N &= P(y \neq y_n) = P(y = 1, y_n = 0) + P(y = 0, y_n = 1) \stackrel{\text{независ.}}{=} P(y = 1)P(y_n = 0) + P(y = 0)P(y_n = 1) \rightarrow 2P(y = 1)P(y = 0) = 2P(1|x)P(0|x) \geq \min\{P(1|x), P(0|x)\}, \\ &\text{так как } P(0|x) + P(1|x) = 1, \text{ т.е. } 2 \max\{P(1|x), P(0|x)\} \geq 1 \end{aligned}$$